DATA Scraping Seminovos Movida

Framework: ITIL 4

Responsável: Borge Pambo

Data: 28/03/2026

1. Visão Geral do Serviço

1.1 Objetivo do Projeto

O projeto tem como objetivo coletar todos os anúncios de carros presentes no site Seminovos Movida, armazenar os dados em formato estruturado e transformá-los em informações analíticas, disponibilizando relatórios e KPIs para acompanhamento do estoque de carros disponíveis para compra online.

1.2 Escopo

- Coleta automatizada de anúncios de veículos.
- Transformação e limpeza dos dados extraídos.
- Armazenamento em camadas **Bronze → Silver → Gold.**
- Geração de agregações e exportação de dados para visualização no Power BI.
- Preparação de relatório com KPIs de estoque, preço médio, km médio e promoções.

1.3 Entregáveis

- **Camada Bronze**: JSON com dados brutos de todos os anúncios coletados.
- **Camada Silver**: CSV com dados limpos, parseados e normalizados.
- **Camada Gold**: DuckDB e Parquet com agregações por marca, modelo, versão e estado.

2. Arquitetura do Serviço

Dashboard Power BI: Indicadores e KPIs sobre estoque, preço médio, km médio e promoções.

2.1 Funções dos Módulos:

Módulo	Função	Camada
extract.py	Coleta dados do site usando Playwright, identifica cards de carro, extrai atributos (marca, modelo, preço, detalhes) e salva em batches JSON.	Bronze
transform.py	Lê arquivos JSON da Bronze, limpa e transforma os dados (parsing de preços, detalhes, título), evita duplicados e salva CSV na Silver.	Gold
Load.py	Lê CSVs Silver, cria tabelas agregadas em DuckDB, calcula KPIs e exporta dados Gold em Parquet	Silver
Main.py	Orquestra o pipeline completo (Extract → Transform → Load), limpa a pasta Bronze antes da execução e registra logs de execução.	Orquestração

2.2 Premissas e Recursos Necessários

Python 3.11+
Ambiente virtual configurado (.myvenv)
Bibliotecas instaladas:

- **playwright** – para scraping e automação do navegador pandas – para manipulação e transformação de dados
- **duckdb** – para armazenamento e agregação analítica Conexão com internet para acesso ao site Seminovos Movida.

2.3 Fluxo ETL e Camadas

- *Extract → Bronze* : Navega no site, rola listas de anúncios e extrai dados de cada carro. Salva os dados em arquivos JSON batched (100 carros por arquivo).
- *Transform → Silver:* Lê arquivos JSON Bronze. Limpa colunas de preço e parcelas, parseia detalhes (km, ano, cidade, estado). Evita duplicados com Silver existente. Salva CSV Silver pronto para análise.
- *Load → Gold* Lê CSVs Silver. Cria tabelas no DuckDB: cars_raw e cars_gold. Calcula KPIs: total de carros, preço médio, km médio, total em promoção. Exporta Gold em formato Parquet.

2.4 Premissas Operacionais

- Scripts devem ser executados sequencialmente (main.py).
- Bronze deve ser limpa antes de cada execução para evitar duplicação.
- Logs detalhados indicam o progresso e possíveis falhas.

3. SOLUÇÕES: Troubleshooting (Ações em caso de erro)

3.1 Erro Possível Causa Ação Corretiva

Erro	Possível Causa	Ação Corretiva
Navegador não abre no `extract.py`	Playwright não instalado ou falha no Chromium	Executar `playwright install` ou reinstalar a biblioteca
JSON Bronze vazio	Falha na coleta ou site alterou layout	Verificar seletor CSS no `extract_car()` e ajustar
CSV Silver não gera dados	Bronze está vazio ou duplicado	Conferir arquivos Bronze, limpar pasta e reexecutar
DuckDB não cria tabelas	Arquivo DuckDB corrompido ou permissão	Apagar arquivo `cars_analytics.duckdb` e rodar `load.py` novamente

Parquet não exporta	Caminho Gold incorreto	Garantir que a pasta `gold/` exista e permissões estejam corretas

4. Tecnologias e Bibliotecas Utilizadas

O projeto utiliza apenas as seguintes bibliotecas principais:

Biblotecas	***Função***
Playwright	Automação do navegador e coleta de dados
Pandas	Manipulação e transformação de dados
DuckbDb	Banco analítico local para armazenamento

Justificativa Tecnológica:

- ✓ **Playwright:** necessário devido ao carregamento dinâmico do site.
- ✓ **Pandas**: simplifica limpeza e transformação dos dados.
- ✓ **DuckDB:** banco leve, rápido e ideal para análises locais.

5. Procedimento Operacional (Como Executar)

5.1 Instalar dependências:

```
pip install -r requirements.txt
```

5.2 Instalar navegador do Playwright:

```
playwright install
```

5.3 Executar Pipeline :

```
python main.py
```

Fluxo executado automaticamente:

- ✓ Extract → Transform → Load

6. Camada de Business Intelligence — Dashboard Power BI

Arquivo: dashboard.pbix

Responsável por:

- ✓ Visualização dos indicadores;
- ✓ Análise exploratória;

6.1 Dashboard Analítico (BI):

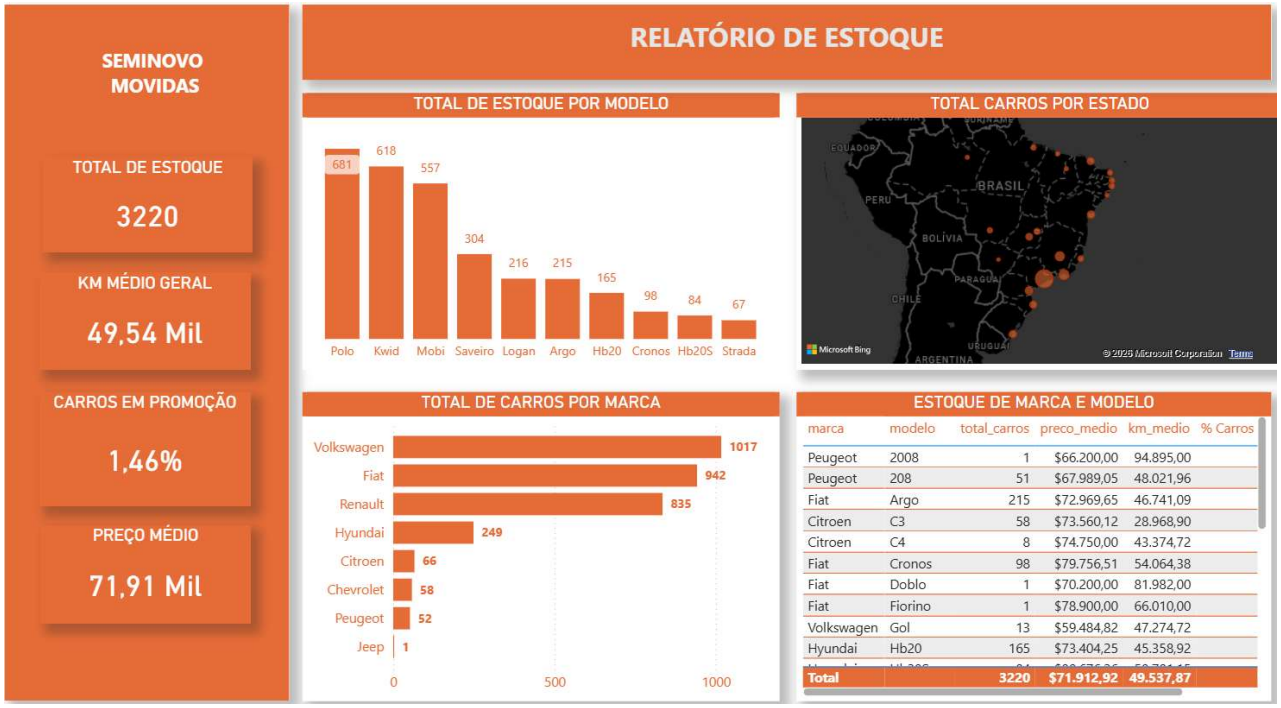

6.2 Cartões (KPIs) do Dashboard:

Na lateral esquerda, existem 4 cartões com os principais indicadores:

1. **TOTAL DE ESTOQUE -** Valor: 6.605

➢ *O que representa: Quantidade total de veículos seminovos disponíveis no estoque*

2. **KM MÉDIO GERAL -** Valor: 45,34 Mil

➢ *O que representa: Média de quilometragem rodada de todos os veículos do estoque*

3. **CARROS EM PROMOÇÃO -** Valor: 1,68%

➢ O que representa: Percentual de veículos que estão com promoção ativa no estoque total

4. **PREÇO MÉDIO -** Valor : R$100,91 Mil

➢ O que representa: Valor médio de venda dos veículos (R$ 100.91 Mil)

7. CONSIDERAÇÕESFINAIS

O projeto implementa um serviço completo de engenharia de dados utilizando arquitetura moderna em camadas e boas práticas de governança operacional alinhadas ao ITIL 4.

Benefícios entregues:

- ✓ Automação da coleta de dados
- ✓ Padronização e qualidade da informação
- ✓ Base analítica estruturada
- ✓ Indicadores estratégicos para tomada de decisão
- ✓ Visualização executiva interativa

O serviço apresenta arquitetura modular, facilitando manutenção, escalabilidade e evolução futura.

Link: https://github.com/BorgePambo/movida-stock-analytics.git